## 08 – Arquivos: fundamentos SCC0503 – Algoritmos e Estruturas de Dados II

Prof. Moacir Ponti Jr. www.icmc.usp.br/~moacir

Instituto de Ciências Matemáticas e de Computação - USP

2011/1

## Sumário

- 📵 Introdução
  - Características do armazenamento secundário em disco
  - Estruturas de arquivos: objetivos e exemplos
  - Histórico
- Operações e fundamentos de arquivos
  - Arquivos Físicos e Lógicos
  - Implementação em C
  - Comandos do sistema de arquivos Unix

## Sumário

- 📵 Introdução
  - Características do armazenamento secundário em disco
  - Estruturas de arquivos: objetivos e exemplos
  - Histórico
- Operações e fundamentos de arquivos
  - Arquivos Físicos e Lógicos
  - Implementação em C
  - Comandos do sistema de arquivos Unix

## Arquivos

Informação mantida em memória secundária

- HD
- Disquetes (old)
- Fitas magnéticas
- CD, DVD e Blu-ray
- Memória flash: pen-drives, mp3-9 player, cartões
- Outros?
- Futuro? bactérias [4], átomos, cristais [5]?

# Terminologia geral

- arquivo: uma estrutura de dados em um sistema de arquivos, que é mapeado para nomes para objetos como arquivos ou diretórios.
- estrutura de arquivo (file structure): um padrão para se organizar dados num arquivo (incluindo ler, escrever e modificar).
- algoritmo: um conjunto finito de regras bem-definidas para a solução de um problema num numero finito de passos.
- estrutura de dados: um padrão para organizar dados num algoritmo ou programa.

## Terminologia de acesos a arquivos

- armazenamento volátil: armazenamento que perde o conteúdo quando não alimentado por energia.
- armazenamento não-volátil: armazenamento que retém o conteúdo quando não alimentado por energia.
- dados persistentes: informação que é retida mesmo após a execução de um programa que a cria.

## Velocidade de acesso

Discos são lentos! (assim como outros dispositivos para armazenamento secundário).

 No entanto s\(\tilde{a}\) o muito \(\tilde{u}\) teis por combinar baixo custo, alta capacidade de armazenamento e portabilidade.

### Quão lentos?

- O tempo de acesso típico em memória principal (RAM) é de  $\approx 70$  nanossegundos, ou 0,00007 milissegundos (já existe tecnologia para acesso em até 10 ns).
- ullet Para acessar a mesma informação em disco, pprox 10 milissegundos (já existem discos com acesso a 8 ms).
- uma diferença da ordem de 140.000 (em configurações típicas atuais, mas essa diferença pode variar entre 100 mil e 300 mil).

## Velocidade de acesso

Uma analogia para entender a diferença na velocidade do acesso:

- se acessar a memória principal é como encontrar uma informação num livro usando o índice desse livro, em 20 segundos,
- acessar o disco seria como ter que fazer uma requisição a uma bibliotecária para que ela procure uma informação numa biblioteca.
- comparativamente, usando o cálculo anterior, significa que obter a informação demoraria por volta de 777,8 horas, ou pouco mais de 32 dias.

# Outras comparações

#### Custo:

• RAM: US\$ 0.05 / Mbit

• HD: US\$ 0.0002 / Mbit

## Capacidade:

• RAM: acima de 1 Gigabyte

• HD: acima de 1 Terabyte

#### Volatilidade:

RAM: volátil

HD: não-volátil

#### Persistência:

- RAM: informação é retida enquanto o programa que controla as variáveis estiver sendo executado.
- HD: informação pode ser persistente.

# Objetivos no estudo de estruturas de arquivo

- Minimizar o número de acessos ao disco: idealmente obter/processar a informação num único acesso
- Maximizar a quantidade de informações recuperadas ou processadas em um acesso, agrupando informações relacionadas.
- De forma independente da tecnologia:
   Tempo de acesso = Número de acessos × tempo de 1 acesso.
- deve-se ter cautela para n\u00e3o projetar uma estrutura de arquivo muito dependente da tecnologia atual (h\u00e1 10-15 anos o uso de disquete e CD era amplo e hoje quase inexistente)

## Estruturas de arquivo

- Estruturas de dados eficientes em memória são muitas vezes inviáveis em disco.
- Um dos problemas em se obter uma estrutura de dados adequada é a constante necessidade de alterações em arquivos.
- O ideal é evitar sequências de acessos (várias requisições à bibliotecária, no exemplo anterior).

# Um exemplo de inviabilidade

O método de busca binária permite que 1 registro pesquisado entre 50 mil seja encontrado em no máximo 16 comparações ( $\log_2(50000) \approx 16$ )

- mas acessar o disco 16 vezes é demais.
- é preciso um método que recupere esse mesmo registro em poucos acessos.
  - agrupar informações para permitir recuperar o máximo de informação em uma única operação de acesso
  - por exemplo, ao consultar um pedido de um cliente e buscar suas informações pessoais (nome, endereço, telefone, CPF, etc.), é preferível obter todas as informações de uma vez ao invés de procurar em vários lugares

## Sumário

- 🕕 Introdução
  - Características do armazenamento secundário em disco
  - Estruturas de arquivos: objetivos e exemplos
  - Histórico
- Operações e fundamentos de arquivos
  - Arquivos Físicos e Lógicos
  - Implementação em C
  - Comandos do sistema de arquivos Unix

### Histórico

Os primeiros trabalhos com arquivos presumiam o armazenamento em fitas

- acesso sequencial
- tamanho dos arquivos cresceu muito e inviabilizou esse tipo de acesso

São, no entanto ainda usadas principalmente para armazenamento off-line redundante pela vida útil longa (até 100 anos)

vide caso de recuperação de perdas do Gmail por backup em fitas.



## Histórico

#### Em discos

- foram adicionados índices aos arquivos que tornaram possível manter uma lista de chaves e ponteiros para acesso aleatório.
- mais uma vez o crescimento dos arquivos de índice tornou difícil a sua manutenção.

Em 1960 o uso de árvores surgiu como solução em potencial, com a desvantagem de crescerem de maneira desigual

- Árvores AVL (1963) foram investigadas para esse problema.
- Árvores-B: demoraram 10 anos para serem desenvolvidas pela diferença de abordagem em disco e RAM — crescimento bottom-up e acesso sequencial as tornaram a base para os sistemas de arquivos.
- Hashing: possibilita acesso em tempo constante, mas em arquivos que não se modifiquem.
- Hashing dinâmico: permitiu modificação no tamanho dos índices e recuperação da informação em no máximo dois acessos.

## Sumário

- 🕕 Introdução
  - Características do armazenamento secundário em disco
  - Estruturas de arquivos: objetivos e exemplos
  - Histórico
- Operações e fundamentos de arquivos
  - Arquivos Físicos e Lógicos
  - Implementação em C
  - Comandos do sistema de arquivos Unix

## Arquivos Físicos e Lógicos

Um arquivo sempre é físico do ponto de vista do armazenamento. É um conjunto de bytes armazenados e rotulados com um nome.

- Para um aplicativo a noção é diferente, pois só é possível acompanhar o fluxo de bytes de leitura e escrita no arquivo.
- O programa é geralmente limitado a 20 conexões com arquivos (analogia com linhas telefônicas).
- Os bytes podem ser orignários de um arquivo físico, do teclado ou outros dispositivos.

Assim, a linha de comunicação aberta pelo sistema operacional para o programa é chamado de <u>arquivo lógico</u>, o que é distinto do <u>arquivo físico</u> no disco ou fita, gerenciado apenas pelo sistema operacional.

## Arquivos Físicos e Lógicos

No código fonte, uma instrução liga o arquivo físico a uma variável lógica. Uma vez ligado, é preciso declarar o que desejamos executar no arquivo. Em geral duas opções:

- abrir um arquivo existente, ou
- criar um novo arquivo, apagando qualquer conteúdo anterior no arquivo físico.

Após abrir um arquivo estaremos posicionados no início do arquivo e portanto prontos para escrever ou ler.

## Sumário

- 🕕 Introdução
  - Características do armazenamento secundário em disco
  - Estruturas de arquivos: objetivos e exemplos
  - Histórico
- Operações e fundamentos de arquivos
  - Arquivos Físicos e Lógicos
  - Implementação em C
  - Comandos do sistema de arquivos Unix

### Dois níveis de manipulação

- funções de baixo nível,
- funções de alto nível:
  - implementadas em baixo nível,
  - mantém área de memória (buffer) para manipulação dos bytes.

```
Na stdio.h: #define :
```

```
#define FOPEN_MAX (20)
typedef struct _iobuf
   char* _ptr;
   int _cnt;
   char* _base;
   int _flag;
   int _file;
   int _charbuf;
   int _bufsiz;
   char* _tmpfname;
} FILE;
```

### Abertura de arquivo:

```
FILE *fd=fopen(<filename>,<flags>)
```

- filename: nome do arquivo a ser aberto
- flags: modo de abertura
  - r: apenas leitura (o arquivo precisa existir)
  - w: cria arquivo vazio para escrita (apaga um arquivo já existente)
  - a: adiciona conteúdo a um arquivo
  - r+: abre arquivo para leitura e escrita
  - w+: cria arquivo vazio para leitura e escrita
  - a+: abre arquivo para leitura e adição de dados
  - b: inserir após as flags anteriores para trabalhar com arquivo binário,
  - caso contrário será aberto em modo texto.

Fechamento de arquivo, transfere o restante da informação no buffer e desliga a conexão com o arquivo físico:

• fd: file descriptor, do tipo o ponteiro FILE

Porque se utiliza buffer?

Grupos de funções para manipulação de arquivos:

- por caractere
- por cadeia de caracteres
- dados formatados
- blocos de bytes

#### Por caractere

- fputc(<char>,<FILE>): escreve um caractere no arquivo,
- <char> = fgetc(<FILE>): lê um caractere do arquivo.

EOF: caractere que indica fim de arquivo. feof(<FILE>): funcão que retorna 1 se fim de arquivo

#### Por cadeia de caracteres

- fputs(<char \*>,<FILE>): escreve uma string no arquivo,
- fgets(<char \*>,<int>,<FILE>): lê do arquivo uma determinada quantidade de caracteres e armazena a cadeia de caracteres numa variável, retorna NULL se fim de arquivo.

#### Por dados formatados

- fprintf(<FILE>,"formatacao", ...): similar ao printf, escreve num arquivo a string formatada.
- fscanf(<FILE>,''formatacao'', ...): similar ao scanf, le do arquivo strings formatadas, retorna EOF se fim de arquivo.

Por blocos de bytes (arquivos binários), assim como estão armazenados na memória principal

- - size\_read: unidades lidas (0 se fim de arquivo),
  - buffer: variavel que vai armazenar a leitura,
  - size\_un: tamanho de cada unidade (bloco) de bytes a ser lido,
  - size\_buffer: número de blocos
  - FILE: ponteiro FILE
- fwrite(<buffer>, <size\_un>, <size\_read>, <FILE>): similar ao scanf, lê do arquivo strings formatadas, retorna EOF se fim de arquivo.

fseek(<FILE>, <move\_bytes>, <start\_byte>): move o ponteiro do arquivo para uma posição determinada.

## Sumário

- 🕕 Introdução
  - Características do armazenamento secundário em disco
  - Estruturas de arquivos: objetivos e exemplos
  - Histórico
- Operações e fundamentos de arquivos
  - Arquivos Físicos e Lógicos
  - Implementação em C
  - Comandos do sistema de arquivos Unix

## Redirecionamento de E/S e Pipes em Unix

O redirecionamento de entrada e saída permite especificar a gravação ou leitura de um arquivo em substituição à entrada: stdin e saída: stdout.

- < file: redireciona stdin para "file"
- > file: redireciona stdout para "file"

Pipes permitem o envio de saídas de um programa para serem usados por outros programas

- programa1 | programa 2: pega a saída stdout do programa1 e usa na entrada stdin do programa2.
- Um exemplo: 1s | sort: a listagem de arquivos é enviada para o programa sort, que as ordena e mostra na tela

## Outros comandos

- cat <filename1> <filename2>...: lista o conteúdo dos arquivos
- tail <filename>: lista as dez últimas linhas do arquivo
- cp <filename1> <filename2>: copia o arquivo1 para o arquivo2
- mv <filename1> <filename2>: move (e renomeia) o arquivo1 para o arquivo2
- rm <filename>: apaga arquivos
- 1s : lista o conteúdo do diretório atual
- mkdir <name>: cria um diretório
- rmdir <name>: remove um diretório
- cd <name>: acessa um diretório

# Bibliografia I

🗫 FOLK, M.J. et al

File Structures: an object-oriented approach with C++ Capítulos 1 e 2

FOLK, M.J. et al

File Structures

Capítulos 1 e 2

YOUNG, J.H.

File Structures

http://www.comsci.us/fs/notes/ch01a.html

DURLEE, D.

Germ of an Idea: Hong Kong Researchers Store Data in Bacteria http://geekbeat.tv/bacteria/

# Bibliografia II



KOVAR, J.F.

GE Unveils 500-GB, Holographic Disc Storage Technology

http://www.crn.com/news/storage/217200230/

ge-unveils-500-gb-holographic-disc-storage-technology.htm